

Хакатон «Нефтекод» 2026

Хакатон направлен на разработку алгоритма предсказания результатов окислительного теста Даймлера (Daimler Oxidation Test, DOT) для многокомпонентных рецептур смазочных материалов. Участникам предстоит построить модель, которая по составу рецептуры, условиям испытания и свойствам компонентов прогнозирует степень изменения вязкости масла и и итоговый показатель окисления. Особенность задачи заключается в том, что в указанных рецептурах число компонентов переменное и разные сочетания компонентов в зависимости от условий эксперимента могут оказывать разное влияние на результат теста Даймлера. Задача осложняется ограниченным объемом данных, включая неоднородность описания состава и свойств компонентов. Поэтому ожидается, что команды будут строить устойчивые и воспроизводимые подходы, способные работать в условиях шума и частичной неопределенности, а также корректно обобщаться на новые сценарии тестирования.

Цель хакатона состоит в достижении алгоритмом высокой точности прогноза окислительного теста Даймлера и получении интерпретируемого с точки зрения физической химии результата – выделении факторов, которые наиболее существенно влияют на прохождение рецептурой окислительного теста Даймлера.

Постановка задачи

Необходимо разработать модель, которая по данным о составе рецептуры, условиям проведения теста и свойствам компонентов предсказывает результаты теста (относительное изменение вязкости и степень окисления). Задача формулируется как регрессия с несколькими выходами: для каждого `scenario_id` из теста требуется получить два численных прогноза: “Delta Kin. Viscosity KV100 - relative | - Daimler Oxidation Test (DOT), %” и “Oxidation EOT | DIN 51453 Daimler Oxidation Test (DOT), A/cm”.

Решение должно быть ориентировано на работу с переменным числом компонентов в рецептуре, устойчивость к неполноте и шуму в описании компонентов, воспроизводимость получения предсказаний и способность обобщения на новые сценарии. Особенное внимание должно быть уделено способности модели выявлять нелинейные эффекты синергии и антагонизма между компонентами. Решение должно явно учитывать возможность таких межкомпонентных взаимодействий и предоставлять инструменты для их анализа и интерпретации. Команда должна представить в составе финального решения анализ релевантных источников (научные статьи, патенты, технические публикации и обзорные материалы). Необходимо убедиться, что даны ответы на следующие вопросы:

1. Какие факторы теста описаны в литературе как значимые?
2. Какие свойства компонентов влияют на результат теста?
3. Какие механизмы окисления и его ингибирования следует учитывать при моделировании?
4. Как найденные закономерности соотносятся с выбранным подходом к построению модели и отбору признаков?

Литературный обзор должен содержать структурированную таблицу гипотез, систематизирующую связь между выявленными в литературе факторами и архитектурой разработанной модели. Таблица должна быть оформлена в формате “Фактор → Механизм влияния на результаты DOT → Каким образом данный фактор учтён в архитектуре модели”. Наличие такой таблицы позволяет оценить, насколько осознанно команда использует предметные знания при проектировании решения.

Данные

Для работы участникам предоставляются файлы `daimler_mixtures_train.csv`, `daimler_mixtures_test.csv` и `daimler_component_properties.csv`.

Файл **`daimler_mixtures_train.csv`** содержит строчное описание состава рецептур для изучения закономерностей и обучения моделей и включает идентификатор сценария `scenario_id` (формат `train_N`), идентификатор компонента (обезличенное название, несущее информацию о типе компонента), идентификатор партии компонента, долю компонента в рецептуре (в преобразованном виде) и параметры условий DOT (температура, время, доля биотоплива, дозировка катализатора). Данный файл также содержит целевые показатели испытания DOT: степень изменения вязкости в ходе теста (`Delta Kin. Viscosity KV100 - relative` | - Daimler Oxidation Test (DOT), %) и степень окисления (`Oxidation EOT` | DIN 51453 Daimler Oxidation Test (DOT), A/cm). Каждому `scenario_id` соответствует несколько строк (по числу компонентов в рецептуре).

Файл **`daimler_mixtures_test.csv`** содержит рецептуры, на которых будет проводиться тестирование разработанных моделей, и включает идентификатор сценария `scenario_id` (формат `test_N`), идентификатор компонента (обезличенное название, несущее информацию о типе компонента), идентификатор партии компонента, долю компонента в рецептуре (в преобразованном виде), параметры условий DOT (температура, время, доля биотоплива, дозировка катализатора). Целевые показатели в этом файле отсутствуют.

Файл **`daimler_component_properties.csv`** содержит свойства компонентов и партий в формате “показатель-значение”. В столбцах таблицы содержатся идентификатор компонента, идентификатор партии компонента, наименование показателя, единица измерения показателя и значение показателя.

Важные замечания:

Дозировка катализатора представлена в категориальном виде (1 или 2), значение 2 отвечает соответствует повышенной (относительно значения 1) дозировке катализатора. Доля других компонентов в данных предоставляется в обезличенном преобразованном виде и не должна трактоваться как истинная концентрация или массовая доля. При этом одинаковые значения преобразованных дозировок соответствуют одинаковым значениям исходных дозировок. Так, например, совпадающая дозировка 70.832 у двух разных компонентов в двух разных сценариях означает, что исходные непреобразованные массовые доли данных компонентов совпадали.

Соотнесение компонентов с их свойствами нужно проводить одновременно и по идентификатору компонента, и по идентификатору партии. Например, компоненту Антиоксидант_6 с партией 13799.21 из сценария train_1 соответствуют свойства, указанные в файле со свойствами для такой пары компонент-партия.

Разные партии одного и того же компонента могут содержать различное число известных свойств.

В наборе данных по свойствам компонентов помимо измеренных значений в конкретных партиях, также представлены типичные значения, помеченные идентификатором партии «typical». При наличии измеренного показателя в рамках конкретной партии, требуется использовать именно его, и только в случае отсутствия – типичное значение.

В данных возможны пропуски и неполные описания компонентов/свойств.

Число компонентов на сценарий переменное.

Сервис преобразования открытых данных

Так как в рамках хакатона предполагается поиск литературных данных, участниками может быть найдена информация об испытаниях, которой можно расширить предоставленную тренировочную выборку. Для преобразования концентраций компонентов, аналогичного проведенному с предоставленными данными, командам будет обеспечен доступ к сервису, принимающему на вход исходную массовую долю, и возвращающему преобразованную массовую долю. Дополнительная информация о сервисе будет сообщена отдельно.

Ограничения на методы

В рамках хакатона запрещается использовать в качестве основного или финального предиктора методы, основанные на деревьях решений и локальном разбиении пространства признаков, включая, но не ограничиваясь, следующие подходы: градиентный бустинг (Gradient Boosting), в том числе алгоритмы XGBoost, LightGBM, CatBoost, случайный лес (Random Forest), ансамбль экстремально рандомизированных деревьев (Extra Trees), а также иные ансамбли деревьев. Допускается использование командами таких методов только для внутренних служебных экспериментов, не входящих в финальное решение и не являющихся его основной частью.

Требования к финальному решению

1. Работа с многокомпонентными рецептурами с переменным числом компонентов;
2. Использование свойств компонентов;
3. Возможность прогнозирования результата DOT на новых данных;
4. Учет химической и физической природы задачи;

5. Использование процедуры отбора признаков;
6. Реализация анализа факторов, оказывающих наибольшее влияние на DOT;
7. Обоснование выбранного подхода;
8. Воспроизводимость и возможность запуска.

Рекомендации к применению алгоритмов

Для интерпретации поведения моделей машинного обучения и оценки влияния параметров сценария и компонентов на результат, рекомендуется использовать различные алгоритмы интерпретации, например, SHAP или LIME. Для решения задачи рекомендуется использовать подходы, способные работать с многокомпонентными системами и сохранять состоятельность при экстраполяции:

1. Модели для множеств компонентов;
2. Архитектуры для обработки множеств (например, Deep Sets);
3. Трансформерные архитектуры для множеств (например, Set Transformer);
4. Иерархические нейросетевые модели;
5. Графовые нейронные сети для представления компонентов;
6. Гибридные модели, объединяющие физически мотивированные признаки и обучаемые представления;
7. Вероятностные и байесовские подходы;
8. Модели с явной структурой взаимодействий между компонентами.

Загрузка на платформу для автоматической проверки

Для автоматической проверки на платформу загружается архив в формате *zip, содержащий два обязательных файла: “predictions.csv” и “inference.ipynb”. Каждая команда будет иметь не более 50 попыток проверки предсказаний своих моделей.

Файл predictions.csv должен содержать три столбца:

1. scenario_id
2. Delta Kin. Viscosity KV100 - relative | - Daimler Oxidation Test (DOT), %
3. Oxidation EOT | DIN 51453 Daimler Oxidation Test (DOT), A/cm

Требуется соблюдать следующие правила корректности для указанных столбцов:

1. Значениям scenario_id должны соответствовать идентификаторы из тестового набора;
2. Для каждого тестового scenario_id должна быть ровно одна строка;
3. Не допускаются пропущенные тестовые идентификаторы;
4. Не допускаются лишние идентификаторы, которых нет в тесте;
5. Не допускаются дубликаты scenario_id;
6. Не допускаются пустые значения в целевых столбцах.

К требованиям к файлу inference.ipynb относятся запуск без ручного редактирования, чтение входных тестовых данных, формирование файла predictions.csv в требуемом формате и обеспечение воспроизводимости результата при повторном запуске в одинаковом окружении.

После загрузки архива *.zip для автоматической проверки, файл predictions.csv проходит валидацию формата; предсказания сравниваются с закрытыми эталонными значениями; рассчитываются метрики качества, оценивающие точность предсказаний двух целевых переменных (средняя ошибка по нормированным значениям с последующим усреднением ошибок по двум целевым переменным); формируется ранжированный список участников.

Тестирование моделей

По результатам автоматизированной проверки, отобранные 10 лучших решений из списка проходят дополнительную экспертную проверку по архиву финального решения. Экспертная проверка включает проверки воспроизводимости, корректности получения предсказаний модели и соблюдения ограничений по методам, а также оценки устойчивости решения, качества работы с многокомпонентной рецептурой, качества отбора признаков и обзора литературы и патентов. Итоговая оценка формируется с учетом следующих критериев автоматической и экспертной проверки:

1. Качество прогнозов модели.
2. Способность модели к экстраполяции.
3. Качество признакового представления – отбор, внесение дополнительных производных показателей.
4. Интерпретация факторов, влияющих на результаты окислительного теста Даймлера.
5. Проработка информации из литературы: статей, патентов, обзоров.
6. Инженерное качество решения.

Финальное решение должно содержать

1. Код обучения модели.
2. Код получения предсказаний модели.
3. ZIP-архив с лучшим результатом для автоматической проверки (файлы `predictions.csv` и `inference.ipynb`).
4. Презентацию решения, включающую:
 - a. Описание используемых признаков и преобразований, с учетом химической и физической природы задачи.
 - b. Описание архитектуры модели, с учетом требования на работу с переменным числом компонентов и использование свойств компонентов.
 - c. Результаты проверки качества модели.

d. Анализ устойчивости и экстраполяции, с оценкой возможности прогнозирования результатов DOT на новых данных.

e. Результаты анализа и отбора ключевых факторов, оказывающих наибольшее влияние на результаты DOT.

f. Обзор релевантной литературы.

g. Слайд на английском языке, содержащий ключевые тезисы презентации (выводы литобзора, архитектуру решения и достигнутые метрики и т.д).

5. Средства контейнерного запуска получения предсказаний модели: обязательно файл сборки контейнера Dockerfile или конфигурация контейнерного запуска Docker Compose (допускается приложить оба).

6. Краткую инструкцию запуска контейнера, которая воспроизводимо формирует файл predictions.csv на тестовом наборе.

Перед сдачей решения команда должна проверить, что приложенный код для получения предсказаний модели запускается вне исходной рабочей среды на другом устройстве или в другой (чистой) папке без артефактов обучения и локальных кэшей. Проверка считается пройденной, если по инструкции из архива из контейнера формируется корректный predictions.csv требуемого формата. При невозможности запустить решение дальнейшая проверка не осуществляется. Вместо этого решения будет взято следующее в ранжировании решение команды, не попавшей в топ-10 ранжированного списка участников.

При обнаружении попытки умышленного подстраивания результатов предсказаний под ранжированный список на платформе с использованием скриптов, случайных или необоснованных данных решение аннулируется. Вместо этого решения будет взято следующее в ранжировании решение команды, не попавшей в топ-10 ранжированного списка.